

实测 HiRouter 的 opencode 路径压缩

会话 1447449062 · 北京时间 2026-09-16 20:54:34 → 23:52:00 · 单机版网关实盘
口径：上游实收 = 上游 usage 实报 input_tokens；压缩前 = 网关本地估算 original_input_tokens（请求 bytes/4，非计费口径）；
真省钱数以上游账单为准；输出 token 假设不变，不计入节省。

1. 实验信息

项	值
会话	1447449062 (opencode, 多轮连续对话, 无 reset)
时间	2026-09-16 20:54:34 → 23:52:00 (北京时间, 约 2 小时 57 分)
网关	HiRouter 单机版 (desktop, opencode 压缩模板默认全开)
上游	zenmux, muse-spark → meta/muse-spark-1.3-contributor, chat_passthrough
数据源	网关结构化日志 (184 条) + 抓包 captures/1447449062 (184 组) + 控制台日志页截图 (尾部)

2. 核心结论

指标	值
总轮数	184, 状态全 ok (成功率 100%)
上游实收输入	10,161,603 tk
压缩前估算	23,571,234 tk
省下	13,409,631 tk (约 1341 万), 压缩率约 56.9%
输出 token	79,679 (未计入, 假设不变)
应用压缩批次 (累计, 含跨轮重复计数)	707
替换消息 (累计, 同上)	47,012 条次
会话重置	0 次

与 9-16 手记"179 轮 / 省约 1262 万"的差异：本次从原始日志独立重算为 184 轮（首条 20:54:34.875 卡着窗口起点；抓包 latest.json seq=184 旁证），多出的 5 轮疑为当时统计时点早于 23:52 收尾。核心结论一致（约 56%），本报告以重算值为准。

3. 压缩行为：首轮预约、176 轮生效、尾部稳定

第 1 轮 (116 条消息) applied=0, 只有预约没有冻结——压缩不改变首轮请求字节，符合"不挡首包"设计。176/184 轮应用压缩并产生替换；尾部连续多轮稳定在每轮应用 7 批次、替换 479 条。截图 tooltip (末轮)：计划 0 / 暂存 0 / 冻结 7 / 本轮应用 7, 替换原始消息 479, 摘要数 7, 跳过原因仅 insufficient_messages_or_tokens (不足阈值, 未硬压)。末轮日志：509 条消息中 22 条符合条件，应用 7 批替换 479 条——替换的是跨轮累积的历史段。

4. 缓存：中位数 97.1%，miss 的轮次由压缩顶上

全程缓存命中率中位数 97.1%，尾部 20 轮中位数 98.3%。31 轮命中率低于 50%（开局爬坡 + 中途读新文件引入新上下文），其中 1 轮 0.0%：输入 46845（原 204977），纯靠压缩省约 15.8 万；第 172 轮输入 120067（原 200265），省约 8 万。结论：压缩保下限，缓存保上限。

5. 延迟：首包不挡，TTFB 中位数 4.8s

TTFB 中位数 4817ms，p95 8239ms，最大 29908ms。摘要任务等主请求 TTFB 后再 spawn，首包延迟主要来自上游模型本身。全程零失败、零熔断、无 reset，会话身份全程稳定。

6. 交叉验证：日志 × 抓包 × 截图三方对上

(1) 抓包序号 0001→0184 连续无缺失，latest.json seq=184，末组时间与日志末条相差 8 秒，同轮 request_id 对上。(2) Wire 独立验算：末 6 轮请求体 bytes/4 与日志原值同量级（高约 8%，系重序列化分隔符差异；按 wire 算省得更多，本报告取保守的日志值）。(3) 截图第一行"56714（原 212884）"与日志末条逐字相等，"已压 7（替换 479 条）"与末 5 轮日志一致。

7. 结论与局限

(1) 网关侧单向压缩有效：opencode 长会话输入 token 省约 56.9%，省的是上游 token，不是本地内存。(2) (原 ...) 是本地估算非计费口径；输出未计。(3) 单会话、单模型、单晚实测，勿外推为普遍承诺；短问答场景省得少。(4) 首轮上游实收 (92879) 大于本地估算 (57218)，压缩未生效轮的估算覆盖口径有差，不影响全程结论，特此注明。

附录 A：逐轮 token 对比




图 1：184 轮"压缩前估算 vs 上游实收"，中间面积即省下的约 1341 万。




图 2: 逐轮缓存命中率 (爬坡 + 中途 miss 可见, 中位数 97.1%)。

附录 B: 控制台日志页尾部截图

状态	首包延迟	上游	模型	输入 tk	输出 tk	缓存命中率	重写详情	Codex 压缩	opcode 压缩
ok	6957 ms	zenimux	muse-spark → meta/muse-spark-1.3-contributor	56714 (原 212884)	77	98.2%	—	—	已压 7 (替换 479 条)
ok	5379 ms	zenimux	muse-spark → meta/muse-spark-1.3-contributor	55742 (原 212148)	948	87.9%	—	—	已压 7 (替换 479 条)
ok	3477 ms	zenimux	muse-spark → meta/muse-spark-1.3-contributor	49083 (原 206837)	127	99.3%	—	—	已压 7 (替换 479 条)
ok	3016 ms	zenimux	muse-spark → meta/muse-spark-1.3-contributor	48879 (原 206661)	176	99.2%	—	—	已压 7 (替换 479 条)
ok	3817 ms	zenimux	muse-spark → meta/muse-spark-1.3-contributor	48535 (原 206360)	554	98.9%	—	—	已压 7 (替换 479 条)
ok	5998 ms	zenimux	muse-spark → meta/muse-spark-1.3-contributor	48067 (原 205988)	392	98.8%	—	—	已压 7 (替换 479 条)
ok	7077 ms	zenimux	muse-spark → meta/muse-spark-1.3-contributor	47558 (原 205613)	636	98.5%	—	—	已压 7 (替换 479 条)
ok	4867 ms	zenimux	muse-spark → meta/muse-spark-1.3-contributor	47396 (原 205450)	120	99.1%	—	—	已压 7 (替换 479 条)
ok	5906 ms	zenimux	muse-spark → meta/muse-spark-1.3-contributor	46987 (原 205116)	968	99.7%	—	—	已压 7 (替换 479 条)
ok	8822 ms	zenimux	muse-spark → meta/muse-spark-1.3-contributor	46845 (原 204977)	691	0.0%	—	—	已压 7 (替换 479 条)
ok	—	—	—	—	—	—	—	—	已暂停
ok	3698 ms	zenimux	muse-spark → meta/muse-spark-1.3-contributor	124876 (原 204719)	241	97.9%	—	—	已压 6 (替换 436 条)
ok	3312 ms	zenimux	muse-spark → meta/muse-spark-1.3-contributor	122337 (原 202399)	281	98.1%	—	—	已压 6 (替换 436 条)

图 3: opencode-test.png——尾部 10 轮"已压 7 (替换 479 条)", tooltip 为末轮批次明细。

原始文件: D:/rust-prj/hirouter/apps/hirouter-desktop/src-tauri/hirouter-logs.json、captures/1447449062/ (1114 文件, 238MB)、D:/swancat-com/opencode-test.png。